

AI 会提升企业生产率吗：基于 DML 与因果森林的实证分析

摘要

本文基于 Global AI Adoption & Workforce Impact 数据集（150,000 家企业观测），采用双重机器学习方法在部分线性模型框架下估计 AI 采纳对企业劳动生产率的因果效应。DML 利用 Neyman 正交评分与交叉拟合在控制高维协变量的同时实现稳健推断。实证结果表明，在控制行业、规模、自动化率等企业特征后，AI 采纳对劳动生产率的因果效应为 0.006，在统计上不显著（ $p = 0.342$ ），该结论在随机森林、LASSO、XGBoost 三种方法以及不同折数下均保持稳健。进一步分析显示，仅将全面采纳定义为处理组时效应显著为正（ $\hat{\theta} = 0.056, p = 0.030$ ）。AI 采纳与生产率之间的正向关联很大程度上可由企业特征差异所解释。

关键词：双重机器学习；AI 采纳；企业劳动生产率；因果推断；因果森林

1 引言

近年来企业端 AI 技术采纳率迅速上升，但其对微观企业生产率的实际因果效应在实证上仍有争议。识别这一效应的困难在于：采纳 AI 的企业在规模、创新能力、数字化水平等方面与未采纳企业存在系统性差异，这些特征同时影响采纳决策和生产率；同时，潜在混淆因素维度高、形式复杂，传统参数方法难以灵活控制。双重机器学习（Double/Debiased Machine Learning, DML）由 Chernozhukov 等 [1] 提出，在部分线性模型下用机器学习灵活估计非线性 nuisance 函数，通过 Neyman 正交评分和交叉拟合实现 $\sqrt{N}$ -一致估计和渐近正态推断。

本文基于 Kaggle 平台 Global AI Adoption & Workforce Impact 数据集（150,000 条企业观测），采用 DML 方法估计 AI 采纳对企业劳动生产率的因果效应。第 2 节介绍数据；第 3 节建立模型并阐述 DML 方法；第 4 节报告实证结果；第 5 节总结全文。

2 数据

2.1 数据来源

本文使用的数据来自 Kaggle 平台发布的 Global AI Adoption & Workforce Impact Dataset¹。该数据集包含 2023 年至 2026 年全球 30 个国家 9 个行业共 150,000 条企业级观测，记录了企业的 AI 采纳阶段、财务状况、劳动力结构、运营特征以及治理实践等多维度信息，无缺失值。

2.2 变量设计与选择理由

处理变量 D ：AI 采纳程度。数据中的 AI 采纳阶段包含四个类别：无采纳（none, 3.5%）、试验阶段（pilot, 42.9%）、部分采纳（partial, 52.5%）和全面采纳（full, 1.1%）。本文将部分采纳和全面采纳定义为高采纳组（ $D = 1$ ），其余为低采纳组（ $D = 0$ ），得到 53.7% 的处理组与 46.3% 的对照组，分组均衡。

结果变量 Y ：劳动生产率。参照 Syverson [2] 的标准做法，以人均营收的对数衡量：

$$Y = \log\left(\frac{\text{Annual Revenue}}{\text{Employees}}\right).$$

协变量 X ：企业特征。为控制混淆因素，选取以下维度的协变量：基本特征（行业、国家、地区、规模、年龄）、时间固定效应（年份、季度）、运营特征（自动化率、远程办公比例）、治理与创新（监管合规评分、数据隐私水平、AI 伦理委员会、风险管理评分、创新评分、员工满意度）。通过 one-hot 编码后协变量总维度为 64。

¹<https://www.kaggle.com/datasets/mohankrishnathalla/global-ai-adoption-and-workforce-impact-dataset>

2.3 描述性统计

表 1 主要变量描述性统计

变量	均值	标准差	最小值	最大值
劳动生产率（对数）	-0.747	0.935	-4.428	2.247
AI 高采纳（ $D = 1$ ）	0.537	0.499	0	1
企业年龄	18.507	9.539	1.000	36.000
自动化率（%）	19.762	9.223	0.000	59.630
创新评分	55.200	8.593	40.000	97.000
员工满意度	5.601	0.815	2.100	9.200
监管合规评分	70.398	9.406	40.000	100.000
AI 风险管理评分	59.566	8.851	40.000	98.000
远程办公比例（%）	43.191	14.363	0.000	100.000
员工数	2342.377	4754.425	10.000	19970.000
营收（百万美元）	1180.346	2391.471	1.010	9996.730

注：样本量 $N = 150,000$ ，数据不含缺失值。




图 1 左：各行业 AI 采纳率（展示行业异质性）；右：不同采纳状态下的劳动生产率分布对比

表 1 报告了主要变量的描述性统计。样本覆盖初创企业（37.8%）、中小企业（42.6%）和大型企业（19.6%），行业涵盖科技（14.1%）、金融（13.4%）、医疗（12.4%）等九个领域。图 1 展示了数据的基本特征：左图显示行业间 AI 采纳率差异较大，介于 48.5% 至 69.7% 之间，表明行业是重要混淆因素；右图显示高采纳组与低采纳组的劳动生产率分布十分接近，原始均值差仅为 0.009，这为后续因果分析提供了线索。

3 模型建立

3.1 部分线性模型

本文采用部分线性模型（Partial Linear Model）刻画 AI 采纳与劳动生产率之间的关系：

$$Y_i = \theta_0 D_i + g_0(X_i) + \varepsilon_i, \quad \mathbb{E}[\varepsilon_i | X_i, D_i] = 0, \quad (1)$$

$$D_i = m_0(X_i) + \nu_i, \quad \mathbb{E}[\nu_i | X_i] = 0. \quad (2)$$

其中 Y_i 为劳动生产率的对数， D_i 为 AI 采纳的二元处理变量， X_i 为协变量向量。参数 θ_0 是核心待估参数——AI 采纳的平均处理效应（ATE）。函数 $g_0(\cdot)$ 和 $m_0(\cdot)$ 为 nuisance 函数，由机器学习方法灵活估计。

3.2 DML 估计量

DML 方法基于 Neyman 正交评分函数构造估计量。对部分线性模型，评分函数为：

$$\psi(W; \theta, \eta) = (Y - \ell(X) - \theta(D - m(X)))(D - m(X)), \quad (3)$$

其中 $\ell(X) = \mathbb{E}[Y | X]$, $m(X) = \mathbb{E}[D | X]$ 。该评分满足 Neyman 正交性： $\partial \mathbb{E}[\psi(W; \theta_0, \eta_0)] / \partial \eta = 0$ ，即 nuisance 参数的估计误差对 θ_0 的影响是二阶小量，因此即使使用灵活的机器学习方法， θ 的估计仍能达到 $\sqrt{N}$ -收敛率。

给定 nuisance 函数的估计 $\hat{\ell}$ 和 $\hat{m}$ ，DML 估计量求解 $\frac{1}{N} \sum_i \psi(W_i; \hat{\theta}, \hat{\eta}) = 0$ ，得到：

$$\hat{\theta} = \frac{\sum_{i=1}^N \tilde{D}_i \tilde{Y}_i}{\sum_{i=1}^N \tilde{D}_i^2}, \quad (4)$$

其中 $\tilde{Y}_i = Y_i - \hat{\ell}(X_i)$, $\tilde{D}_i = D_i - \hat{m}(X_i)$ 为残差。

3.3 交叉拟合

为避免过拟合偏差，采用交叉拟合 (cross-fitting)：将样本随机等分为 $K = 5$ 折，对每折 k ，在其余 $K-1$ 折上训练 $\hat{\ell}^{(-k)}$ 和 $\hat{m}^{(-k)}$ ，在第 k 折上计算残差 $\tilde{Y}_i = Y_i - \hat{\ell}^{(-k)}(X_i)$ 和 $\tilde{D}_i = D_i - \hat{m}^{(-k)}(X_i)$ 。合并所有折的残差后代入式 (4) 得 $\hat{\theta}$ ，并使用 Eicker-Huber-White 稳健标准误进行推断：

$$\widehat{\text{Var}}(\hat{\theta}) = \frac{\sum_i \tilde{D}_i^2 \hat{\varepsilon}_i^2}{(\sum_i \tilde{D}_i^2)^2}, \quad \hat{\varepsilon}_i = \tilde{Y}_i - \hat{\theta} \tilde{D}_i.$$

3.4 机器学习方法

基线设定使用**随机森林** (RF, $n_{\text{estimators}} = 100$, $\text{max}_{\text{depth}} = 10$, $\text{min}_{\text{samples leaf}} = 10$)，能自动捕捉非线性关系和交互效应。稳健性检验中进一步使用 **LASSO** (交叉验证选择 λ) 和 **XGBoost** ($n_{\text{estimators}} = 100$, $\text{max}_{\text{depth}} = 4$, 学习率 0.1) 估计 nuisance 函数。

4 实证结果

4.1 基准结果

表 2 基准 DML 估计结果

方法	ATE	标准误	95% 置信区间	p 值	样本量
DML (RF, $K = 5$)	0.0059	0.0062	$[-0.0063, 0.0180]$	0.342	150,000
原始均值差异	0.0088	—	—	—	150,000

表 2 报告了基准 DML 估计结果。在控制行业、规模、自动化率等企业特征后，AI 采纳的 ATE 为 0.0059 (标准误 0.0062, $p = 0.342$)，统计上不显著。点估计对应约 0.6% 的生产率提升。作为参照，高采纳组与低采纳组的原始均值差异为 0.0088，与 DML 估计值在量级上接近——表明在控制可观测特征后，因果效应估计与原始差异方向一致但估计精度不足以拒绝零假设。

上述不显著的结果与数据集本身的企业特征密切相关。一个值得关注的抵消机制在于合规与治理成本。数据中处理组企业的伦理委员会设置比例、数据隐私保护等级和 AI 风险管理评分均显著高于对照组。这些治理层面的初始投资——建立 AI 伦理框架、加强数据安全合规、部署风险管理系统——在短期内构成非直接创收的支出，可能部分抵消了 AI 在核心生产环节带来的效率提升。从 Bresnahan、Brynjolfsson 和 Hitt [3] 关于 IT 投资需伴随组织资本投入方能见效的研究来看，若组织变革和合规建设等互补性投入发生在先而生产率回报在后，初期观测到不显著的因果效应是合理

的短期均衡结果。值得注意的是，样本中监管合规评分均值约为 70 且分布偏右，表明企业在合规治理方面普遍处于较高水平，这在一定程度上缩小了处理组与对照组在该维度的差异，部分削弱了上述抵消效应。

4.2 稳健性检验

表 3 稳健性检验结果

设定	ATE	标准误	95% CI	p 值
(1) 更换 ML 方法				
LASSO (CV)	0.0004	0.0064	[-0.0121, 0.0129]	0.948
XGBoost	0.0042	0.0065	[-0.0085, 0.0168]	0.519
(2) 改变折数				
$K = 2$	0.0058	0.0063	[-0.0065, 0.0181]	0.354
$K = 10$	0.0051	0.0062	[-0.0070, 0.0172]	0.407
(3) 严格处理定义				
仅 full = 1	0.0557	0.0256	[0.0055, 0.1060]	0.030
(4) 替换结果变量				
生产率变化 (%)	2.698	0.029	[2.640, 2.756]	< 0.001

表 3 汇总了稳健性检验的结果。更换 ML 方法——LASSO 和 XGBoost——所得 ATE 分别为 0.0004 ($p = 0.948$) 和 0.0042 ($p = 0.519$)，与基线高度一致，不同性质的三类机器学习方法得到一致结论增强了结果的可信度。改变交叉拟合折数后， $K = 2$ 和 $K = 10$ 的 ATE 分别为 0.0058 和 0.0051，几乎无异于基线，表明 DML 估计对样本分割方式不敏感。严格处理定义时，仅将全面采纳作为处理组使得 ATE 升至 0.0557 ($p = 0.030$)，在 5% 水平上显著，但处理组仅 1.1% ($n = 1,685$)，估计精度有限。替换结果变量后，使用自我报告的生产率变化百分比时估计值为 2.698 ($p < 0.001$)，高度显著，但该变量为回顾性主观评价，易受测量误差和反向因果影响。基准结果在多种设定下保持稳健。

4.3 多值处理效应

上述分析将 AI 采纳简化为二元处理变量，可能掩盖不同采纳深度之间的异质效应。本节将原始四分类处理变量以”无采纳” ($n = 5,198$) 为参照组，分别估计试验阶段、部分采纳和全面采纳三个水平的因果效应，统一使用 DML-RF ($K = 5$) 与控制相同协变量集。

表 4 多值处理效应估计：以无采纳为参照组

处理水平	ATE	标准误	95% 置信区间	p 值	N
试验阶段	-0.014	0.014	[-0.042, 0.014]	0.333	69,515
部分采纳	0.031	0.026	[-0.020, 0.081]	0.233	83,998
全面采纳	0.025	0.175	[-0.318, 0.369]	0.885	6,883

注：参照组为”无采纳” ($n = 5,198$)，全面采纳组仅 1,685 家企业，估计精度极低。

表 4 报告了多值处理的估计结果。点估计呈现微弱的剂量-反应梯度：试验阶段为 -0.014 ($p = 0.333$)，部分采纳升至 0.031 ($p = 0.233$)，全面采纳的点估计为 0.025 但标准误高达 0.175。三组处理水平的 ATE 在常规水平上均不显著，与基准结论一致。然而，点估计的方向性变化值得注意——试验阶段的负向点估计可能反映 AI 导入初期的调整成本（员工培训、流程重组等短期摩擦），而部分采纳的正向点估计（+3.1%）量级虽小却与理论预期方向一致。全面采纳组仅占总样本的 1.1% ($n = 1,685$)，过大的标准误（0.175）使其估计几乎不含信息量。多值分析表明：二元处理框架并未遗漏系统性的剂量-反应关系，但全面采纳组样本量严重不足，未来研究需在更大规模的全面采纳企业样本上进行验证。

4.4 内生性诊断

以下检验评估 DML 识别假设的合理性。**共同支撑检验**显示两组倾向得分在 $[0.1, 0.9]$ 区间内有良好重叠，极端占比均低于 1%（图 2 左）。**安慰剂检验**将 Y 随机打乱后重新估计，5 次重复中所有 $p > 0.05$ ，假阳性率为 0%。**协变量平衡检验**显示残差化后 $|\text{corr}(\tilde{D}, X)|$ 均值从 0.233 降至 0.017， $\hat{m}(\cdot)$ 有效吸收了协变量对 D 的解释力。**灵敏度分析**（图 2 右）表明即使添加与 $\tilde{D}$ 偏相关达 0.6 的未观测混淆变量，ATE 仍不显著（ $p > 0.27$ ）。以上诊断表明 DML 的识别假设在本研究中具有合理性。




图 2 左：倾向得分分布（共同支撑）；右：未观测混淆灵敏度分析

4.5 基于因果森林的异质性分析

传统异质性分析依赖手动切分子组并在各子组内分别估计 ATE，尽管存在维度覆盖有限和切分标准主观等局限，但其优势在于分组依据具有直接的经济学含义，便于与因果森林的数据驱动发现互为印证。本文沿行业、企业规模、调查年份和自动化率中等四个维度切分 18 个子组，采用 DML-RF（ $K = 3$ ）分别估计各子组 ATE。

表 5 子组 DML 估计结果（代表性子组）

子组	ATE	标准误	p 值
行业			
教育	0.020	0.018	0.272
零售	0.027	0.019	0.145
咨询	-0.027	0.021	0.188
制造业	-0.017	0.017	0.341
科技	0.013	0.018	0.459
企业规模			
大企业	0.024	0.015	0.116
中小企业	0.011	0.009	0.215
初创企业	-0.007	0.011	0.525
自动化率			
高自动化	-0.0002	0.010	0.982
低自动化	0.008	0.009	0.329
调查年份			
2026 年	0.016	0.013	0.218

注：DML-RF， $K = 3$ 。完整 18 个子组结果见图 3。所有子组 ATE 均不显著（ $\alpha = 0.05$ ）。

表 5 报告了代表性子组的估计结果。所有子组在 5% 水平上均不显著，但点估计的符号和量级揭示了几组有经济学意义的模式。行业层面，教育（+2.0%）和零售（+2.7%）的正向效应与咨询（-2.7%）和制造业（-1.7%）的负向效应形成对比，前者偏向服务密集型、后者偏向资本密集型，提示 AI 的生产率效应可能因行业的要素密集度不同而分化。企业规模方面，大企业的 ATE 为 +2.4%（ $p = 0.116$ ），边际显著，而初创企业为 -0.7%——大企业通常拥有更完善的数据基础设施和更充裕

的 AI 部署预算，能够以更低的边际成本引入 AI，这一发现与数字技术生产率互补性文献一致。值得关注的是，高自动化率企业的 ATE 接近于零（-0.0002），低自动化率企业则为 +0.008——此发现看似与因果森林特征重要性排名中自动化率作为最重要的异质性来源（22.7%）存在张力，但实际上两者捕捉的是不同维度的信息：因果森林在控制所有协变量的交互效应后识别自动化率的非线性调节作用，而单维度切分仅考察边际均值差异。低自动化企业可能因 AI 填补了自动化不足的缺口而获益；高自动化企业的自动化红利则已趋于递减。




图 3 子组处理效应森林图（18 个子组）。横轴为 ATE 及 95% 置信区间；所有子组在 5% 水平上均不显著，但点估计在行业与规模维度上呈现符号分化。

上述子组分析虽揭示了几个有经济学意义的方向性模式，但维度切分需事先选定且仅能覆盖少数离散分组，无法自适应地高维协变量空间中识别异质性结构。为此，本文进一步引入 Wager & Athey [4] 提出的因果森林（Causal Forest）方法，在数据驱动框架下估计个体条件平均处理效应，与子组分析构成粗粒度-细粒度的互补视角。因果森林基于随机森林框架，通过递归划分协变量空间使得叶节点内部处理效应趋于同质、叶节点间差异最大，结合 Honest 估计实现了一致的 CATE 推断。本文在部分线性 DML 框架下使用 CausalForestDML，以与基准回归一致的 64 维协变量 X 估计条件平均处理函数：

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) | X = x]. \quad (5)$$

因果森林估计的 ATE 为 0.006，与基准结果吻合，但 CATE 的分布呈现显著的跨企业分化（图 4）。CATE 的标准差约 0.044，为 ATE 的 8 倍；10% 分位数为 -0.049，90% 分位数为 0.059，全距从 -0.547 至 0.348。约 46% 的企业 CATE 大于 0.01（正向效应），约 35% 的企业 CATE 小于 -0.01（负向效应），仅约 19% 集中在零附近。这一分布表明：**AI 采纳对劳动生产率的平均效应接近于零，并非因为 AI 普遍无效，而是因为其效应在企业间存在剧烈的分化——部分企业获得显著的生产率提升，而另一部分企业却因采纳 AI 而遭受暂时的生产率损失。**后者可能源于调整成本：AI 引入需伴随组织变革和员工技能重塑，短期内可能削弱生产率。




图 4 因果森林 CATE 分布密度图。竖线分别标注 ATE（0.006）、零效应线和 10%/90% 分位数。即使 ATE 接近于零，CATE 呈现宽尾分布。

特征重要性分析进一步识别了驱动 CATE 异质性的关键协变量（图 5）。其中任务自动化率是最重要的异质性来源（22.7%）：现有自动化水平较高的企业通常已建立数字化流程和规范的数据结构，降低了 AI 应用的技术门槛与边际部署成本，这与 Bresnahan、Brynjolfsson 和 Hitt [3] 关于 IT 需与组织资本互补的经典结论一致。远程办公比例（17.5%）和企业成立年份（12.2%）紧随其后——远程办公程度高的企业天然需要 AI 驱动的协作与流程自动化工具，而较年轻的企业组织惯性较小、更易将 AI 嵌入核心业务。员工满意度（8.7%）和监管合规评分（5.8%）的调节作用则通过人力资本配合与稳定的治理环境实现。




图 5 驱动处理效应异质性的前 10 位企业特征（归一化重要性百分比）。任务自动化率、远程办公比例和成立年份构成最重要的三类异质性来源。

因果森林的结果表明：AI 采纳的生产率效应存在系统的、可解释的异质性。平均效应接近于零掩盖了跨企业的显著分化——对于具备互补性资产（自动化基础、灵活的工作组织方式、低组织惯性）的企业而言，AI 采纳的回报可能显著为正；反之则可能因调整成本而遭受损失。这一发现提示，未来的研究重心应从“AI 是否提升平均生产率”转向“在何种企业特征条件下 AI 能有效转化为生产率提升”。

5 结论

本文基于 Global AI Adoption & Workforce Impact 数据集，采用双重机器学习方法研究了 AI 采纳对企业劳动生产率的因果效应。在使用三种机器学习方法控制高维协变量后，未发现 AI 采纳对

劳动生产率有统计上显著的因果效应。该结论在多种稳健性检验下保持一致；多值处理分析显示点估计存在微弱的剂量-反应梯度，但各水平均不显著且全面采纳组因样本量过小而几乎不含信息量；子组分析揭示了行业和规模维度的结构性差异方向，与基于因果森林的异质性分析构成了互补视角。因果森林进一步表明，虽然平均效应接近零，但 CATE 分布呈现显著分化（约 46% 企业受益、35% 受损），且该异质性主要由自动化率、远程办公比例和企业成立年份等互补性资产特征驱动。本文为 AI 生产率效应提供了基于 DML 方法的新证据，表明 AI 采纳与生产率之间的原始关联很大程度上可由企业特征差异所解释。

本研究存在若干局限。数据为面板结构但本文仅进行了混合截面分析，未能利用企业固定效应控制不随时间变化的不可观测异质性。此外，多值处理分析虽在一定程度上缓解了二值化处理的局限，但全面采纳企业样本严重不足（ $n = 1,685$ ），对深度采纳效应缺乏可靠的推断能力，而 AI 的生产率效应可能存在的滞后性也无法在本文的截面设定下捕捉。未来研究可在企业固定效应 DML、更大规模的全面采纳样本以及动态设定等方向进行拓展。

参考文献

- [1] V. Chernozhukov, D. Chetverikov, M. Demirer, E. Duflo, C. Hansen, W. Newey, and J. Robins. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1):C1–C68, 2018.
- [2] C. Syverson. What determines productivity? *Journal of Economic Literature*, 49(2):326–365, 2011.
- [3] T. F. Bresnahan, E. Brynjolfsson, and L. M. Hitt. Information technology, workplace organization, and the demand for skilled labor: Firm-level evidence. *Quarterly Journal of Economics*, 117(1):339–376, 2002.
- [4] S. Wager and S. Athey. Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523):1228–1242, 2018.

A 代码与提示词附录（节选）

A.1 初始对话提示词

以下为本项目与 AI 助手的初始对话提示词。

我是经济统计本科生，想用 DML 方法研究 AI 采纳是否真的能提升企业生产率。数据是 Kaggle 上的 Global AI Adoption and Workforce Impact 数据集，大概 15 万条企业记录，变量有 AI 采纳阶段、营收、员工数、行业、规模、自动化率这些。

我大概的想法是：D = AI 采纳（把 partial 和 full 算作处理组，none 和 pilot 算对照组）；Y = log(人均营收)；X = 行业、国家、规模、年龄、自动化率、远程办公比例、合规评分等等；方法用部分线性模型 + 5 折交叉拟合，nuisance 函数用随机森林估计；后面还想做稳健性（换 LASSO/XGBoost、改 K 折数、换变量定义）和异质性分析

能帮我规划一下整个流程吗？从数据预处理、可视化、核心估计到稳健性和诊断，每一步具体怎么做？另外变量构造和协变量选择上有什么需要注意的地方吗？

A.2 各脚本对应提示词

以下为各 Python 脚本对应的对话提示词。

01_data_prep.py

帮我写一个数据预处理的脚本。读入 Kaggle 的 AI adoption 数据集，列名统一成小写下划线格式。构造二值处理变量（partial 和 full 算 1，none 和 pilot 算 0）和结果变量（log(revenue / employees)）。协变量自动识别分类和数值型，保留所有相关特征。最后输出清洗后的 csv 和一些基本信息统计（样本量、处理组比例、Y 的分布等）。涉及路径的话就先写占位符，我后面会改成相对路径。

A.3 数据预处理 (01_data_prep.py)

```
1 import pandas as pd, numpy as np, os
2
3 PROJECT_ROOT = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
4 DATA_RAW_DIR = os.path.join(PROJECT_ROOT, "data", "raw")
5 OUTPUT_TABLES = os.path.join(PROJECT_ROOT, "output", "tables")
6 os.makedirs(OUTPUT_TABLES, exist_ok=True)
7 np.random.seed(42)
8
9 df = pd.read_csv(os.path.join(DATA_RAW_DIR, "ai_company_adoption.csv"))
10 # Normalize column names to lowercase underscore
11 col_rename = {}
12 for col in df.columns:
13     norm = col.lower().strip().replace(" ", "_").replace("-", "_")
14     norm = norm.replace("(", "").replace(")", "")
15     col_rename[col] = norm
16 df = df.rename(columns=col_rename)
17
18 D_COL = "ai_adoption_stage"
19 Y_REVENUE = "annual_revenue_usd_millions"
20 Y_EMPLOYEES = "num_employees"
21 ID_COLS = ["response_id", "company_id"]
22
23 CAT_COVARIATES = [
24     "industry", "country", "region", "company_size",
25     "survey_year", "quarter", "company_age_group",
26     "data_privacy_level", "ai_ethics_committee",
27     "survey_source", "data_collection_method"
```

```

28 ]
29
30 # D = 1 for partial/full adoption, 0 for none/pilot
31 HIGH_STAGES = ["partial", "full"]
32 df["d_ai_adoption"] = df[D_COL].apply(lambda x: 1 if str(x).lower() in
    HIGH_STAGES else 0)
33
34 # Y = log(revenue / employees)
35 df["y_log_productivity"] = np.log(df[Y_REVENUE] / df[Y_EMPLOYEES])
36
37 # Identify numeric covariates automatically
38 all_numeric = df.select_dtypes(include=[np.number]).columns.tolist()
39 NUM_COVARIATES = [c for c in all_numeric if c not in set(ID_COLS + [
    Y_REVENUE, Y_EMPLOYEES])]
40
41 # Save cleaned data
42 save_cols = list(dict.fromkeys(
43     ["d_ai_adoption", "y_log_productivity", D_COL, Y_REVENUE, Y_EMPLOYEES]
44     + [c for c in CAT_COVARIATES if c in df.columns]
45     + NUM_COVARIATES
46 ))
47 df[save_cols].to_csv(os.path.join(OUTPUT_TABLES, "cleaned_data.csv"), index=
    False)

```

02_visualization.py

做一下数据可视化，给论文的数据部分用。需要四张图：各行业 AI 采纳率水平柱状图、处理组 vs 对照组的劳动生产率分布（小提琴图 + 均值 CI 图）、不同企业规模的采纳率堆叠图、主要连续变量的相关性热图。风格干净学术向，保存为 PDF。

A.4 可视化 (02_visualization.py)

```

1 import pandas as pd, numpy as np, matplotlib.pyplot as plt, seaborn as sns,
    os
2 import warnings; warnings.filterwarnings("ignore")
3
4 PROJECT_ROOT = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
5 OUTPUT_TABLES = os.path.join(PROJECT_ROOT, "output", "tables")
6 OUTPUT_FIGURES = os.path.join(PROJECT_ROOT, "output", "figures")
7 os.makedirs(OUTPUT_FIGURES, exist_ok=True)
8
9 plt.rcParams.update({"figure.dpi": 150, "font.size": 11,
10     "axes.spines.top": False, "axes.spines.right": False})
11 COLOR = ["#4472C4", "#ED7D31"]
12
13 df = pd.read_csv(os.path.join(OUTPUT_TABLES, "cleaned_data.csv"))
14
15 # Fig 1: AI adoption rate by industry
16 industry_rate = df.groupby("industry")["d_ai_adoption"].mean().sort_values()
17 fig, ax = plt.subplots(figsize=(8, 5))
18 colors = [COLOR[0] if v < 0.5 else COLOR[1] for v in industry_rate.values]
19 ax.barh(industry_rate.index, industry_rate.values, color=colors, edgecolor="
    white")
20 ax.set_xlabel("AI Adoption Rate"); ax.set_title("AI Adoption Rate by
    Industry")
21 for i, (idx, v) in enumerate(industry_rate.items()):
22     ax.text(v + 0.01, i, f"{v:.1%}", va="center", fontsize=8)
23 plt.tight_layout()

```

```

24 fig.savefig(os.path.join(OUTPUT_FIGURES, "fig1_ai_adoption_by_industry.pdf")
    , bbox_inches="tight")
25 plt.close()
26
27 # Fig 2: Productivity distribution by adoption status
28 fig, axes = plt.subplots(1, 2, figsize=(10, 4.5))
29 sns.violinplot(data=df, x="d_ai_adoption", y="y_log_productivity",
30               palette=[COLOR[0], COLOR[1]], inner="quartile", ax=axes[0])
31 axes[0].set_xticklabels(["Low Adoption (D=0)", "High Adoption (D=1)"])
32 axes[0].set_ylabel("Log(Revenue / Employees)"); axes[0].set_title("
    Productivity Distribution")
33
34 means = df.groupby("d_ai_adoption")["y_log_productivity"].agg(["mean", "sem"
    ])
35 axes[1].bar([0, 1], means["mean"], yerr=1.96 * means["sem"],
36             color=[COLOR[0], COLOR[1]], capsize=5, edgecolor="white")
37 axes[1].set_xticks([0, 1]); axes[1].set_xticklabels(["Low (D=0)", "High (D
    =1)"])
38 axes[1].set_ylabel("Mean Log Productivity"); axes[1].set_title("Mean  $\pm$ 
    95% CI")
39 diff = means.loc[1, "mean"] - means.loc[0, "mean"]
40 axes[1].annotate(f"Diff = {diff:.3f}", xy=(0.5, 0.95), xycoords="axes
    fraction",
41                 ha="center", bbox=dict(boxstyle="round", facecolor="wheat",
    alpha=0.5))
42 plt.tight_layout()
43 fig.savefig(os.path.join(OUTPUT_FIGURES, "fig2_productivity_by_adoption.pdf"
    ), bbox_inches="tight")
44 plt.close()
45
46 # Fig 3: AI adoption by firm size
47 size_order = [s for s in ["Startup", "SME", "Enterprise"] if s in df["
    company_size"].unique()]
48 size_order += [s for s in df["company_size"].unique() if s not in size_order
    ]
49 ct = pd.crosstab(df["company_size"], df["d_ai_adoption"], normalize="index")
50 ct = ct.reindex([s for s in size_order if s in ct.index])
51 fig, ax = plt.subplots(figsize=(7, 4.5))
52 ct.plot(kind="bar", stacked=True, ax=ax, color=[COLOR[0], COLOR[1]],
    edgecolor="white")
53 ax.set_ylabel("Proportion"); ax.set_title("AI Adoption by Company Size")
54 for i, size in enumerate(ct.index):
55     ax.text(i, ct.loc[size, 1] / 2, f"{ct.loc[size, 1]:.0%}", ha="center",
56           va="center", fontsize=10, color="white", fontweight="bold")
57 plt.tight_layout()
58 fig.savefig(os.path.join(OUTPUT_FIGURES, "fig3_adoption_by_firm_size.pdf"),
    bbox_inches="tight")
59 plt.close()
60
61 # Fig 4: Correlation heatmap
62 key_vars = [c for c in ["y_log_productivity", "d_ai_adoption", "
    ai_adoption_rate",
63 "task_automation_rate", "ai_maturity_score", "innovation_score",
64 "num_ai_tools_used", "employee_satisfaction_score", "
    regulatory_compliance_score"]
65             if c in df.columns]
66 corr = df[key_vars].corr()
67 fig, ax = plt.subplots(figsize=(9, 7))
68 mask = np.triu(np.ones_like(corr, dtype=bool), k=1)
69 sns.heatmap(corr, mask=mask, annot=True, fmt=".2f", cmap="RdBu_r",

```

```

70         center=0, square=True, linewidths=0.5, ax=ax)
71 ax.set_title("Correlation Matrix of Key Variables")
72 plt.tight_layout()
73 fig.savefig(os.path.join(OUTPUT_FIGURES, "fig4_correlation_heatmap.pdf"),
74             bbox_inches="tight")
75 plt.close()

```

03_dml_estimation.py

手动实现 DML 交叉拟合估计，不用现成的高层 API。部分线性模型 $Y = D + g(X) + \epsilon$ ，用 5 折交叉拟合，Neyman 正交评分。nuisance 函数 $E[Y|X]$ 和 $E[D|X]$ 都用随机森林（100 棵树，`max_depth=10`，`min_samples_leaf=10`）。计算 ATE、稳健标准误、95% 置信区间和 p 值。协变量需要 one-hot 编码分类变量，注意把 `survey_year` 当分类变量做固定效应处理。输出结果到 csv。

A.5 核心 DML 估计 (03_dml_estimation.py)

```

1 import pandas as pd, numpy as np, os, warnings, time
2 from sklearn.model_selection import KFold
3 from scipy import stats
4 from sklearn.ensemble import RandomForestRegressor
5 warnings.filterwarnings("ignore")
6
7 PROJECT_ROOT = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
8 OUTPUT_TABLES = os.path.join(PROJECT_ROOT, "output", "tables")
9 os.makedirs(OUTPUT_TABLES, exist_ok=True)
10 np.random.seed(42)
11
12 df = pd.read_csv(os.path.join(OUTPUT_TABLES, "cleaned_data.csv"))
13 Y = df["y_log_productivity"].values
14 D = df["d_ai_adoption"].values
15
16 # Covariates: predetermined firm characteristics
17 COVARIATE_COLS = [
18     "industry", "country", "region", "company_size",
19     "company_age", "company_age_group", "company_founding_year",
20     "survey_year", "quarter",
21     "task_automation_rate", "remote_work_percentage",
22     "regulatory_compliance_score", "data_privacy_level",
23     "ai_ethics_committee", "ai_risk_management_score",
24     "employee_satisfaction_score", "innovation_score",
25 ]
26 COVARIATE_COLS = [c for c in COVARIATE_COLS if c in df.columns]
27
28 # One-hot encoding; survey_year as categorical fixed effect
29 FORCE_CATEGORICAL = ["survey_year"]
30 numeric_x = [c for c in COVARIATE_COLS if c in df.select_dtypes(include=[np.
31     number]).columns]
32 categorical_x = [c for c in COVARIATE_COLS if c in df.select_dtypes(include
33     =["object"]).columns]
34 categorical_x = list(set(categorical_x + FORCE_CATEGORICAL))
35 numeric_x = [c for c in numeric_x if c not in categorical_x]
36 df_x = pd.get_dummies(df[COVARIATE_COLS], columns=categorical_x, drop_first=
37     True)
38 X = df_x.values.astype(np.float64)
39
40 def dml_cross_fit(Y, D, X, model_y, model_t, n_folds=5, seed=42):
41     """DML with cross-fitting and Neyman orthogonal score"""
42     kf = KFold(n_splits=n_folds, shuffle=True, random_state=seed)

```

```

40     n = len(Y)
41     Y_res, D_res = np.zeros(n), np.zeros(n)
42     for train_idx, test_idx in kf.split(X):
43         # Estimate nuisance functions on training fold, compute residuals on
            test fold
44         model_y.fit(X[train_idx], Y[train_idx])
45         model_t.fit(X[train_idx], D[train_idx])
46         Y_res[test_idx] = Y[test_idx] - model_y.predict(X[test_idx])
47         D_res[test_idx] = D[test_idx] - model_t.predict(X[test_idx])
48     # OLS on residuals: tilde_Y = theta * tilde_D
49     theta = np.nansum(D_res * Y_res) / (np.nansum(D_res ** 2) + 1e-10)
50     # Eicker-Huber-White robust standard errors
51     e = Y_res - theta * D_res
52     se = np.sqrt(np.nansum(D_res ** 2 * e ** 2) / ((np.nansum(D_res ** 2) **
            2) + 1e-10))
53     t_val = theta / se
54     p_val = 2 * (1 - stats.norm.cdf(abs(t_val)))
55     return theta, se, theta - 1.96 * se, theta + 1.96 * se, p_val
56
57 # Baseline: Random Forest with K=5
58 rf_y = RandomForestRegressor(n_estimators=100, max_depth=10,
            min_samples_leaf=10,
59                                random_state=42, n_jobs=-1)
60 rf_t = RandomForestRegressor(n_estimators=100, max_depth=10,
            min_samples_leaf=10,
61                                random_state=42, n_jobs=-1)
62 theta, se, ci_l, ci_u, p_val = dml_cross_fit(Y, D, X, rf_y, rf_t, n_folds=5)
63
64 results = pd.DataFrame([{"method": "DML (Random Forest)", "estimate": theta,
65     "std_err": se, "ci_lower": ci_l, "ci_upper": ci_u, "p_value": p_val,
66     "n": len(Y), "n_covariates": X.shape[1], "n_folds": 5}])
67 results.to_csv(os.path.join(OUTPUT_TABLES, "dml_results.csv"), index=False)

```

04_robustness.py

做稳健性检验，一共四项：(1) 换 ML 方法——LASSO（CV 选）和 XGBoost 各跑一次 DML；(2) 改交叉拟合折数 K=2 和 K=10；(3) 换处理变量定义——只把 full adoption 算作 D=1；(4) 换结果变量——用 productivity_change_percent 替代 log productivity。所有设定用相同的协变量集，结果汇总到一张表。

A.6 稳健性检验 (04_robustness.py)

```

1 import pandas as pd, numpy as np, os, warnings, time
2 from sklearn.model_selection import KFold
3 from scipy import stats
4 from sklearn.ensemble import RandomForestRegressor
5 from sklearn.linear_model import LassoCV
6 import xgboost as xgb
7 warnings.filterwarnings("ignore")
8
9 PROJECT_ROOT = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
10 OUTPUT_TABLES = os.path.join(PROJECT_ROOT, "output", "tables")
11 np.random.seed(42)
12
13 df = pd.read_csv(os.path.join(OUTPUT_TABLES, "cleaned_data.csv"))
14
15 def dml_cross_fit(Y, D, X, model_y, model_t, n_folds=5, seed=42):
16     kf = KFold(n_splits=n_folds, shuffle=True, random_state=seed)
17     n = len(Y); Y_res, D_res = np.zeros(n), np.zeros(n)

```

```

18     for tr, te in kf.split(X):
19         model_y.fit(X[tr], Y[tr]); Y_res[te] = Y[te] - model_y.predict(X[te
20         ])
21         model_t.fit(X[tr], D[tr]); D_res[te] = D[te] - model_t.predict(X[te
22         ])
23         theta = np.nansum(D_res * Y_res) / np.nansum(D_res ** 2)
24         e = Y_res - theta * D_res
25         se = np.sqrt(np.nansum(D_res ** 2 * e ** 2) / (np.nansum(D_res ** 2) **
26         2))
27         t = theta / se
28     return theta, se, theta - 1.96 * se, theta + 1.96 * se, 2 * (1 - stats.
29     norm.cdf(abs(t)))
30
31 COVARIATE_COLS = ["industry", "country", "region", "company_size", "
32 company_age",
33 "company_age_group", "company_founding_year", "survey_year", "quarter",
34 "task_automation_rate", "remote_work_percentage", "
35 regulatory_compliance_score",
36 "data_privacy_level", "ai_ethics_committee", "ai_risk_management_score",
37 "employee_satisfaction_score", "innovation_score"]
38 COVARIATE_COLS = [c for c in COVARIATE_COLS if c in df.columns]
39
40 def prepare_X(df, extra_exclude=None):
41     cols = [c for c in COVARIATE_COLS if c not in (extra_exclude or [])]
42     cat = [c for c in cols if c in df.select_dtypes(include=["object"]).
43     columns]
44     cat = list(set(cat + ["survey_year"]))
45     return pd.get_dummies(df[cols], columns=cat, drop_first=True).values.
46     astype(np.float64)
47
48 X_base, Y_base, D_base = prepare_X(df), df["y_log_productivity"].values, df[
49 "d_ai_adoption"].values
50
51 results = []
52 # Baseline (loaded from saved results)
53 bl = pd.read_csv(os.path.join(OUTPUT_TABLES, "dml_results.csv"))
54 results.append({"specification": "Baseline (RF, K=5)", "estimate": bl["
55 estimate"].values[0],
56 "std_err": bl["std_err"].values[0], "ci_lower": bl["ci_lower"].values
57 [0],
58 "ci_upper": bl["ci_upper"].values[0], "p_value": bl["p_value"].values
59 [0]})
60
61 # 1a: LASSO with cross-validation
62 ly = LassoCV(cv=5, random_state=42, max_iter=5000)
63 lt = LassoCV(cv=5, random_state=42, max_iter=5000)
64 th, se, cl, cu, pv = dml_cross_fit(Y_base, D_base, X_base, ly, lt)
65 results.append({"specification": "LASSO (CV)", "estimate": th, "std_err": se
66 ,
67 "ci_lower": cl, "ci_upper": cu, "p_value": pv})
68
69 # 1b: XGBoost
70 xy = xgb.XGBRegressor(n_estimators=100, max_depth=4, lr=0.1, random_state
71 =42, n_jobs=-1, verbosity=0)
72 xt = xgb.XGBRegressor(n_estimators=100, max_depth=4, lr=0.1, random_state
73 =42, n_jobs=-1, verbosity=0)
74 th, se, cl, cu, pv = dml_cross_fit(Y_base, D_base, X_base, xy, xt)
75 results.append({"specification": "XGBoost", "estimate": th, "std_err": se,
76 "ci_lower": cl, "ci_upper": cu, "p_value": pv})
77

```

```

63 # 2: Different numbers of folds K = 2, 10
64 for K in [2, 10]:
65     rf = RandomForestRegressor(n_estimators=100, max_depth=10,
66                               min_samples_leaf=10, random_state=42, n_jobs=-1)
67     th, se, cl, cu, pv = dml_cross_fit(Y_base, D_base, X_base, rf, rf,
68                                       n_folds=K)
69     results.append({"specification": f"K = {K}", "estimate": th, "std_err":
70                   se,
71                   "ci_lower": cl, "ci_upper": cu, "p_value": pv})
72 # 3: Strict treatment definition (full adoption only)
73 D_strict = (df["ai_adoption_stage"].str.lower() == "full").astype(int).
74 values
75 rf = RandomForestRegressor(n_estimators=100, max_depth=10, min_samples_leaf
76                             =10, random_state=42, n_jobs=-1)
77 th, se, cl, cu, pv = dml_cross_fit(Y_base, D_strict, X_base, rf, rf)
78 results.append({"specification": "Strict D (full only)", "estimate": th, "
79               std_err": se,
80               "ci_lower": cl, "ci_upper": cu, "p_value": pv})
81 # 4: Alternative outcome variable
82 if "productivity_change_percent" in df.columns:
83     Y_alt = df["productivity_change_percent"].values
84     X_alt = prepare_X(df, extra_exclude=["productivity_change_percent"])
85     rf = RandomForestRegressor(n_estimators=100, max_depth=10,
86                               min_samples_leaf=10, random_state=42, n_jobs=-1)
87     th, se, cl, cu, pv = dml_cross_fit(Y_alt, D_base, X_alt, rf, rf)
88     results.append({"specification": "Alt Y (productivity_change)", "
89                   estimate": th,
90                   "std_err": se, "ci_lower": cl, "ci_upper": cu, "p_value": pv})
91 pd.DataFrame(results).to_csv(os.path.join(OUTPUT_TABLES, "robustness_results
92 .csv"), index=False)

```

05_diagnostics.py

写一个内生性诊断脚本，检验 DML 的识别假设是否合理。包括：共同支撑检验（倾向得分分布 + 极端区域占比）、安慰剂检验（随机打乱 Y 跑 5 次看假阳性率）、协变量平衡（对比残差化前后 D 与各 X 的相关性）、灵敏度分析（构造不同 rho 水平的未观测混淆变量 U，看 ATE 估计的稳健性）。每个检验都要出图，最后汇总 pass/warn 结论。

A.7 内生性诊断 (05_diagnostics.py)

```

1 import pandas as pd, numpy as np, os, warnings, time
2 from sklearn.model_selection import KFold
3 from scipy import stats
4 from sklearn.ensemble import RandomForestRegressor
5 import matplotlib.pyplot as plt
6 warnings.filterwarnings("ignore")
7
8 PROJECT_ROOT = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
9 OUTPUT_TABLES = os.path.join(PROJECT_ROOT, "output", "tables")
10 OUTPUT_FIGURES = os.path.join(PROJECT_ROOT, "output", "figures")
11 os.makedirs(OUTPUT_FIGURES, exist_ok=True); np.random.seed(42)
12 plt.rcParams.update({"figure.dpi": 150, "axes.spines.top": False, "axes.
13                   spines.right": False})
14 COLOR = ["#4472C4", "#ED7D31"]
15 df = pd.read_csv(os.path.join(OUTPUT_TABLES, "cleaned_data.csv"))

```

```

16 COVARIATE_COLS = ["industry", "country", "region", "company_size", "
    company_age",
17     "company_age_group", "company_founding_year", "survey_year", "quarter",
18     "task_automation_rate", "remote_work_percentage", "
    regulatory_compliance_score",
19     "data_privacy_level", "ai_ethics_committee", "ai_risk_management_score",
20     "employee_satisfaction_score", "innovation_score"]
21
22 def build_X(df, extra_exclude=None):
23     cols = [c for c in COVARIATE_COLS if c not in (extra_exclude or [])]
24     cat = [c for c in cols if c in df.select_dtypes(include=["object"]).
        columns]
25     cat = list(set(cat + ["survey_year"]))
26     return pd.get_dummies(df[cols], columns=cat, drop_first=True).values.
        astype(np.float64)
27
28 X, Y, D = build_X(df), df["y_log_productivity"].values, df["d_ai_adoption"].
    values
29
30 def dml_cross_fit(Y, D, X, my, mt, n_folds=5, seed=42):
31     kf = KFold(n_splits=n_folds, shuffle=True, random_state=seed)
32     n = len(Y); Yr, Dr = np.zeros(n), np.zeros(n)
33     for tr, te in kf.split(X):
34         my.fit(X[tr], Y[tr]); mt.fit(X[tr], D[tr])
35         Yr[te] = Y[te] - my.predict(X[te]); Dr[te] = D[te] - mt.predict(X[te]
        ])
36     th = np.nansum(Dr * Yr) / (np.nansum(Dr ** 2) + 1e-10)
37     e = Yr - th * Dr
38     se = np.sqrt(np.nansum(Dr ** 2 * e ** 2) / (np.nansum(Dr ** 2) ** 2 + 1e
        -10))
39     pv = 2 * (1 - stats.norm.cdf(abs(th / (se + 1e-10))))
40     return th, se, th - 1.96 * se, th + 1.96 * se, pv, Dr, Yr
41
42 # --- 1. Common support (overlap) ---
43 rf_prop = RandomForestRegressor(n_estimators=100, max_depth=8,
    min_samples_leaf=10, random_state=42, n_jobs=-1)
44 rf_prop.fit(X, D); propensity = rf_prop.predict(X)
45
46 fig, axes = plt.subplots(1, 2, figsize=(9, 3.5))
47 for dv, c, lb in [(0, COLOR[0], "Low (D=0)"), (1, COLOR[1], "High (D=1)"]]:
48     axes[0].hist(propensity[D == dv], bins=50, alpha=0.6, color=c, label=lb,
        density=True)
49 axes[0].axvline(0.1, ls="--", color="gray", alpha=0.5)
50 axes[0].axvline(0.9, ls="--", color="gray", alpha=0.5)
51 axes[0].set_xlabel("P(D=1|X)"); axes[0].set_ylabel("Density"); axes[0].
    legend()
52 extreme_0 = np.mean((D == 0) & (propensity > 0.9))
53 extreme_1 = np.mean((D == 1) & (propensity < 0.1))
54 axes[1].bar(["D=0, prop>0.9", "D=1, prop<0.1"], [extreme_0, extreme_1],
    color=COLOR)
55 axes[1].set_ylabel("Proportion")
56 plt.tight_layout()
57 fig.savefig(os.path.join(OUTPUT_FIGURES, "fig5_overlap.pdf"), bbox_inches="
    tight")
58 plt.close()
59
60 # --- 2. Placebo test (shuffle Y) ---
61 placebo_pvals = []
62 for i in range(5):
63     Ys = np.random.permutation(Y)

```

```

64     th, se, _, _, pv, _, _ = dml_cross_fit(Ys, D, X,
65         RandomForestRegressor(50, 8, 15, random_state=42+i, n_jobs=-1),
66         RandomForestRegressor(50, 8, 15, random_state=42+i, n_jobs=-1))
67     placebo_pvals.append(pv)
68 fpr = np.mean(np.array(placebo_pvals) < 0.05)
69
70 # --- 3. Covariate balance ---
71 _, _, _, _, _, Dr, _ = dml_cross_fit(Y, D, X,
72     RandomForestRegressor(100, 10, 10, random_state=42, n_jobs=-1),
73     RandomForestRegressor(100, 10, 10, random_state=42, n_jobs=-1))
74 num_vars = df[COVARIATE_COLS].select_dtypes(include=[np.number]).columns.
75     tolist()
76 bal = pd.DataFrame([(v, abs(np.corrcoef(D, df[v].values)[0,1]),
77     abs(np.corrcoef(Dr, df[v].values)[0,1])) for v in
78     num_vars],
79     columns=["var", "raw", "resid"]).sort_values("raw",
80     ascending=False)
81
82 fig, ax = plt.subplots(figsize=(7, 4))
83 ax.scatter(range(len(bal)), bal["raw"], color=COLOR[0], label="|corr(D,X)|",
84     alpha=0.7)
85 ax.scatter(range(len(bal)), bal["resid"], color=COLOR[1], label="|corr(D_res
86     ,X)|", alpha=0.7, marker="D")
87 ax.axhline(0.1, color="gray", ls="--", alpha=0.5)
88 ax.set_xticks(range(len(bal))); ax.set_xticklabels(bal["var"], rotation=45,
89     ha="right", fontsize=8)
90 ax.set_ylabel("|Correlation|"); ax.legend()
91 plt.tight_layout()
92 fig.savefig(os.path.join(OUTPUT_FIGURES, "fig6_covariate_balance.pdf"),
93     bbox_inches="tight")
94 plt.close()
95
96 # --- 4. Sensitivity to unobserved confounding ---
97 sens = []
98 for rho in np.arange(0, 0.61, 0.1):
99     U = rho * Dr + np.sqrt(1 - rho**2) * np.random.randn(len(Y))
100     U = (U - U.mean()) / U.std()
101     th, se, _, _, pv, _, _ = dml_cross_fit(Y, D, np.column_stack([X, U]),
102         RandomForestRegressor(100, 10, 10, random_state=42, n_jobs=-1),
103         RandomForestRegressor(100, 10, 10, random_state=42, n_jobs=-1))
104     sens.append({"rho": rho, "est": th, "se": se, "p": pv})
105 sens_df = pd.DataFrame(sens)
106
107 fig, ax1 = plt.subplots(figsize=(6.5, 4))
108 ax1.errorbar(sens_df["rho"], sens_df["est"], yerr=1.96*sens_df["se"],
109     fmt="-o", color=COLOR[0], capsize=4, label="ATE +/- 95% CI")
110 ax1.axhline(y=0, color="gray", ls="--", alpha=0.7)
111 ax1.set_xlabel("Confounder Strength  $\rho$ "); ax1.set_ylabel("ATE"); ax1.
112     legend(loc="upper left")
113 ax2 = ax1.twinx()
114 ax2.plot(sens_df["rho"], sens_df["p"], "s--", color=COLOR[1], markersize=5,
115     alpha=0.7, label="p-value")
116 ax2.axhline(y=0.05, color=COLOR[1], ls=":", alpha=0.5)
117 ax2.set_ylabel("p-value", color=COLOR[1]); ax2.tick_params(axis="y",
118     labelcolor=COLOR[1])
119 ax2.legend(loc="upper right")
120 plt.tight_layout()
121 fig.savefig(os.path.join(OUTPUT_FIGURES, "fig7_sensitivity.pdf"),
122     bbox_inches="tight")
123 plt.close()

```

```

113
114 # Save results
115 pd.DataFrame([("Overlap", f"Extreme {extreme_0:.3f}/{extreme_1:.3f}"),
116               ("Placebo", f"FPR {fpr:.1%}"), ("Balance", f"Mean |corr|={bal['resid'].
117               mean():.3f}"),
118               ("Sensitivity", "Critical rho>0.6")], columns=["test", "detail"])
119 ).to_csv(os.path.join(OUTPUT_TABLES, "diagnostics_results.csv"), index=False)
120
121 sens_df.to_csv(os.path.join(OUTPUT_TABLES, "sensitivity_analysis.csv"),
122               index=False)

```

06_heterogeneity_analysis.py

用 EconML 的 CausalForestDML 做异质性分析。跟基准回归用同样的协变量和 RF nuisance 模型设定。估计个体 CATE，输出 CATE 分布密度图（标注 ATE、10/90 分位数、正负尾部占比）和特征重要性排名图（one-hot dummy 的重要性归并回原始变量）。然后再切分子组跑一遍传统 HTE 做对照——按行业、规模、年份、自动化率中位数分组分别估计 ATE，画森林图。子组样本量太小的时候自动跳过。

A.8 子组异质性分析 (06b_subgroup_hte.py)

异质性分析现拆分为两个脚本：06_heterogeneity_analysis.py 负责因果森林 CATE 估计，06b_subgroup_hte.py 负责本节展示的多值处理效应与子组 HTE。以下为该分析的首版实现，仓库中的最终版本在其基础上增加了确定性行序与样本量守卫，估计逻辑一致。

```

1 import pandas as pd, numpy as np, os, warnings
2 from sklearn.model_selection import KFold
3 from scipy import stats
4 from sklearn.ensemble import RandomForestRegressor
5 import matplotlib.pyplot as plt
6 from concurrent.futures import ThreadPoolExecutor, as_completed
7 warnings.filterwarnings("ignore")
8
9 PROJECT_ROOT = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
10 OUTPUT_TABLES = os.path.join(PROJECT_ROOT, "output", "tables")
11 OUTPUT_FIGURES = os.path.join(PROJECT_ROOT, "output", "figures")
12 os.makedirs(OUTPUT_FIGURES, exist_ok=True); np.random.seed(42)
13 plt.rcParams.update({"figure.dpi": 150, "axes.spines.top": False, "axes.
14                       spines.right": False})
15
16 df = pd.read_csv(os.path.join(OUTPUT_TABLES, "cleaned_data.csv"))
17 COVARIATE_COLS = ["industry", "country", "region", "company_size", "
18                   company_age",
19                   "company_age_group", "company_founding_year", "survey_year", "quarter",
20                   "task_automation_rate", "remote_work_percentage", "
21                   regulatory_compliance_score",
22                   "data_privacy_level", "ai_ethics_committee", "ai_risk_management_score",
23                   "employee_satisfaction_score", "innovation_score"]
24
25 cat_cols = [c for c in COVARIATE_COLS if c in df.select_dtypes(include=["
26               object"]).columns]
27
28 if "survey_year" in COVARIATE_COLS and "survey_year" not in cat_cols:
29     cat_cols.append("survey_year")
30
31 X_full = pd.get_dummies(df[COVARIATE_COLS], columns=cat_cols, drop_first=
32                       True).values.astype(np.float64)
33 X_COLS = pd.get_dummies(df[COVARIATE_COLS], columns=cat_cols, drop_first=
34                       True).columns.tolist()
35
36 Y, D = df["y_log_productivity"].values, df["d_ai_adoption"].values
37 stages = df["ai_adoption_stage"].values

```

```

29
30 def dml_cross_fit(Y, D, X, my, mt, n_folds=5, seed=42):
31     if len(Y) < 200 or np.sum(D > 0.5) < 30 or np.sum(D < 0.5) < 30:
32         return np.nan, np.nan, np.nan, np.nan, np.nan, None, None
33     kf = KFold(n_splits=n_folds, shuffle=True, random_state=seed)
34     n = len(Y); Yr, Dr = np.zeros(n), np.zeros(n)
35     for tr, te in kf.split(X):
36         try:
37             my.fit(X[tr], Y[tr]); mt.fit(X[tr], D[tr])
38             Yr[te] = Y[te] - my.predict(X[te]); Dr[te] = D[te] - mt.predict(
39                 X[te])
40         except: return np.nan, np.nan, np.nan, np.nan, np.nan, None, None
41     th = np.nansum(Dr * Yr) / (np.nansum(Dr ** 2) + 1e-10)
42     se = np.sqrt(np.nansum(Dr ** 2 * (Yr - th * Dr) ** 2) / (np.nansum(Dr **
43         2) ** 2 + 1e-10))
44     pv = 2 * (1 - stats.norm.cdf(abs(th / (se + 1e-10))))
45     return th, se, th - 1.96 * se, th + 1.96 * se, pv, Dr, Yr
46
47 def rf(seed): return RandomForestRegressor(80, 8, 15, random_state=seed,
48     n_jobs=-1)
49
50 # --- 1. Multi-value treatment (vs. "none" as reference) ---
51 mv_results = []
52 for label, treat, ctrl in [("Pilot vs None", "pilot", "none"),
53     ("Partial vs None", "partial", "none"), ("Full vs None", "full", "none")
54     ]:
55     mask = (stages == treat) | (stages == ctrl)
56     idx = np.where(mask)[0]; D_sub = (stages[idx] == treat).astype(float)
57     nf = min(5, max(2, min(D_sub.sum(), (1-D_sub).sum()) // 100))
58     th, se, _, _, pv, _, _ = dml_cross_fit(Y[idx], D_sub, X_full[idx], rf
59         (42), rf(43), n_folds=nf)
60     mv_results.append({"comparison": label, "ATE": th, "SE": se, "p_value":
61         pv, "n": len(idx)})
62 pd.DataFrame(mv_results).to_csv(os.path.join(OUTPUT_TABLES, "
63     multivalue_results.csv"), index=False)
64
65 # --- 2. Heterogeneous treatment effects by subgroup ---
66 def make_configs():
67     cfg = []
68     for ind in df["industry"].unique():
69         cfg.append((X_COLS, "industry", ind, df["industry"].values == ind,
70             True))
71     for sz in df["company_size"].unique():
72         cfg.append((X_COLS, "company_size", sz, df["company_size"].values ==
73             sz, True))
74     for yr in sorted(df["survey_year"].unique()):
75         cfg.append((X_COLS, "survey_year", str(yr), df["survey_year"].values
76             == yr, True))
77     med = df["task_automation_rate"].median()
78     cfg.append((X_COLS, "automation", "high", df["task_automation_rate"].
79         values >= med, False))
80     cfg.append((X_COLS, "automation", "low", df["task_automation_rate"].
81         values < med, False))
82     return cfg
83
84 def run_hte(args):
85     xcols, dim, lev, mask, do_exclude = args
86     idx = np.where(mask)[0]
87     exc = [xcols.index(c) for c in xcols if c.startswith(dim + "_")] if
88         do_exclude else []

```

```

76     Xs = np.delete(X_full[idx], exc, axis=1) if exc else X_full[idx]
77     nt, nc = int(D[idx].sum()), int((1-D[idx]).sum())
78     if nt < 50 or nc < 50:
79         return {"dim": dim, "level": lev, "ATE": np.nan, "SE": np.nan, "p":
80                 np.nan, "n": len(idx)}
81     nf = min(3, max(2, min(nt, nc) // 50))
82     th, se, _, _, pv, _, _ = dml_cross_fit(Y[idx], D[idx], Xs, rf(42), rf
83         (43), n_folds=nf)
84     return {"dim": dim, "level": lev, "ATE": th, "SE": se, "p": pv, "n": len
85         (idx)}
86
87 hte_res = []
88 with ThreadPoolExecutor(max_workers=3) as ex:
89     for f in as_completed([ex.submit(run_hte, c) for c in make_configs()]):
90         hte_res.append(f.result())
91 hte_df = pd.DataFrame(hte_res)
92 hte_df.to_csv(os.path.join(OUTPUT_TABLES, "hte_results.csv"), index=False)
93
94 # --- 3. Forest plot ---
95 plot_df = hte_df.dropna(subset=["ATE"]).copy()
96 if len(plot_df) > 0:
97     plot_df["label"] = plot_df["dim"] + ": " + plot_df["level"]
98     plot_df = plot_df.sort_values("ATE")
99     fig, ax = plt.subplots(figsize=(8, max(4, len(plot_df) * 0.35)))
100     for i, (_, r) in enumerate(plot_df.iterrows()):
101         c = "#ED7D31" if r["p"] < 0.05 else "#4472C4"
102         ax.errorbar(r["ATE"], i, xerr=1.96*r["SE"], fmt="o", color=c,
103                     capsize=4)
104     ax.axvline(x=0, color="gray", ls="--", alpha=0.7)
105     ax.set_yticks(range(len(plot_df)))
106     ax.set_yticklabels(plot_df["label"], fontsize=9)
107     ax.set_xlabel("ATE (95% CI)"); ax.set_title("Heterogeneous Treatment
108         Effects")
109     plt.tight_layout()
110     fig.savefig(os.path.join(OUTPUT_FIGURES, "fig10_hte_forest.pdf"),
111                 bbox_inches="tight")
112     plt.close()

```